RÜCKSPRACHE / ENTSCHEIDUNGSVORLAGE

Wann hilft dynamikbasierte Regularisierung?

Imitation Learning mit robomimic | Master-Projektarbeit | 3 Monate

Hypothese: Eine nach lokaler Modellgültigkeit gewichtete BC-Regularisierung erhöht die Erfolgsrate nach echten Störungen gegenüber derselben ungewichteten Methode, ohne die nominale Leistung wesentlich zu senken.

Das Problem

Behavioral Cloning (BC) lernt, Expertenaktionen nachzuahmen. Bei der Ausführung führen kleine Abweichungen jedoch zu Zuständen, die in den Demonstrationen kaum vorkamen. Ein zusätzlicher Lernterm soll Korrektur fördern. Wenn sein Dynamikmodell falsch ist, kann er auch falsche Reaktionen belohnen.

Der geplante Beitrag

Eine begrenzte Erweiterung in robomimic implementieren, die zugrunde liegenden Modellannahmen prüfen und den Nutzen kontrolliert messen. Die Policyarchitektur bleibt gleich. Vorarbeiten sind Stable-BC und CCIL; die allgemeine Idee ist bereits bekannt [S3-S5].

Passend zum verfügbaren Rahmen

Kern: offizieller Lift-PH-Datensatz, Zustandsmerkmale, kleines BC-Netz, zunächst am eigenen PC. **Optional:** eine zweite Aufgabe, bevorzugt Can. Das Rechenzentrum ab etwa Woche 7 erweitert den Umfang; der Kern bleibt lokal abschließbar.

Entscheidung nach Woche 3

Erst prüfen, ob die Dynamiknäherung tragfähig ist. Falls nicht: Wechsel zur vorbereiteten Studie über zeitlich strukturierte Sensoraugmentation. Ein negativer Befund zur Modellgültigkeit bleibt wissenschaftlich auswertbar.

Für die Rücksprache vereinbaren: erwarteter Methodenbeitrag, erlaubter Simulatorzugang, Mindestumfang und Umgang mit negativen Ergebnissen.

Die Idee braucht eine klare Abgrenzung

Gezielte Primärquellenrecherche bis 12.10.2026. Neue Preprints sind Hinweise; ihre Aussagen werden nicht als gesicherter Konsens behandelt.

Vorarbeit	Konsequenz für das Projekt
robomimic CoRL 2021 / Dokumentation [S1-S2]	BC, zeitliche Modelle und Diffusion Policy sind verfügbar. Datenqualität, Beobachtungen und Evaluation mitkontrollieren.
Diffusion Policy RSS 2023 [S6]	Moderne Aktionsfolgen-Policy. Eine breite Architekturreplikation würde den kleinen Robustheitsversuch vergrößern.
Stable-BC RA-L 2025 [S3]	Regularisiert lokale Fehlerdynamik. Seine Garantien gelten unter Annahmen; sie übertragen sich nicht automatisch auf unseren Zusatzloss.
CCIL und Feinmanipulation ICLR / IROS 2024 [S4-S5]	Lokale Modelle, korrigierende Labels und Fehlerfilter existieren bereits. Unser Gegenstand ist ein gewichteter Lernterm und seine empirische Gültigkeit.
Kontraktive Policies ICLR 2025 / 2026 [S9-S10]	Kontraktion einer Policy oder des Diffusionssamplers ist von Kontraktion des physischen Roboterfehlers zu unterscheiden.
Action-Chunking-Analysen August / Oktober 2026 [S7-S8] *Preprints*	Untersuchen Ensembling und Fehlerausbreitung. Der Messhorizont beeinflusst Stabilitätsdiagnosen; mehrere Horizonte als Zusatzdiagnose verwenden.

Die abgeleitete Untersuchungslücke

Wann bringt ein unabhängig geprüfter lokaler Dynamikterm in diesem robomimic-Aufbau einen Zusatznutzen gegenüber einfacher Sensoraugmentation und beliebiger Gewichtung? Das ist eine konkrete empirische Frage; ein weltweiter Neuheitsanspruch ist noch nicht belegt.

Lesereihenfolge: robomimic-Studie → Stable-BC → CCIL / Feinmanipulation → aktuelle Abgrenzung. DAgger und DART sind Bezugspunkte für zusätzliche Expertenkorrekturen [S11-S12].

Zwei Störungen, zwei Lernziele

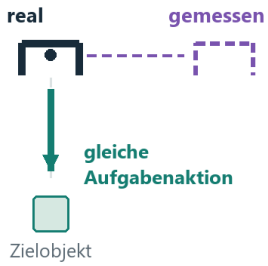
FORSCHUNGSIDEE · ROBUSTES IMITATION LEARNING

Zwei Störungen – zwei Lernziele

Was die Policy ignorieren sollte und worauf sie reagieren muss.

01 Sensorfehler

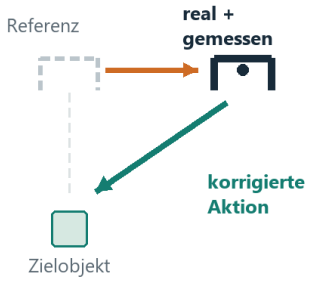
Nur die Messung ist verändert.



Lernziel: möglichst messfehler-invariant

02 Physische Zustandsabweichung

Der reale Zustand ist verändert.



Lernziel: Abweichung aktiv verkleinern

Prüfbare Frage

Hilft ein Dynamikmodell bei realen Abweichungen über reine Sensoraugmentation hinaus?

Schematische Illustration – keine Versuchsdaten. Aktionen sind idealisierte Lernziele, keine Modellvorhersagen.

Was die neue Gewichtung leisten soll

Der Zusatzloss schätzt, ob eine kleine Zustandsabweichung nach einer korrigierenden Aktion schrumpft. **A** beschreibt die offene Zustandsantwort, **B** die zusätzliche Aktionswirkung. Die Gewichtung **w** soll unzuverlässige Modellbereiche weniger stark berücksichtigen.

BC-Loss + λ × gewichteter Korrektur-Loss

Konzeptionell: $\hat{e}_{t+1} = A\,\delta + B\,\Delta a$

Die entscheidende Grenze

Kleine Fehler im Modell können eine falsche Korrektur begünstigen. Deshalb A/B durch getrennte Zustands- und Aktionsinterventionen prüfen. Erst danach trainieren. Gute Anpassung an Expertentrajektorien allein genügt nicht.

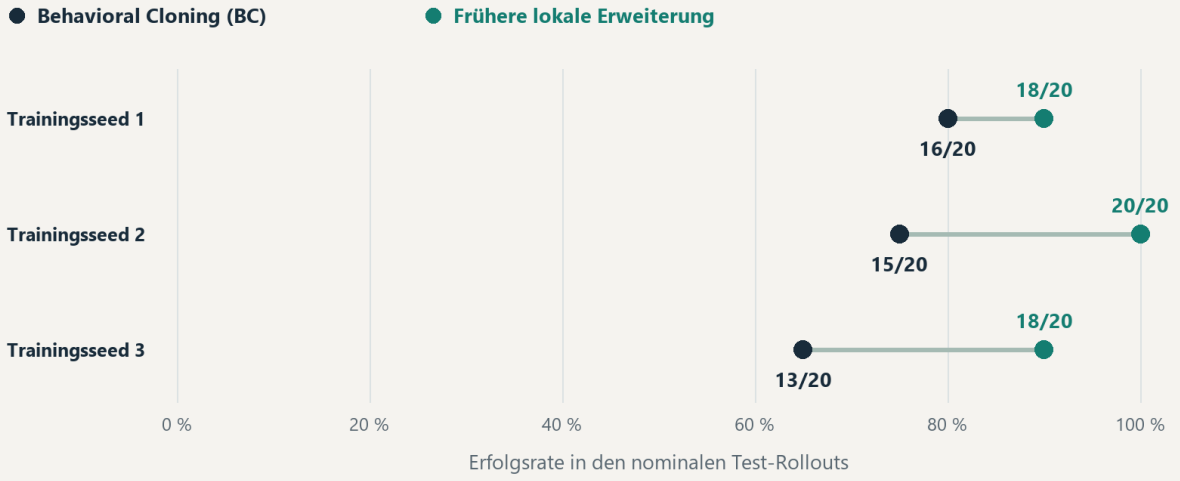
Die Kalibrierung verwendet zusätzliche Simulatorinformation beim Training. Bei Ausführung erhält die Policy dieselben Beobachtungen wie BC. Dies ist simulationsgestütztes IL; keine allgemeine Stabilitätsgarantie.

Ein positiver Anlass - und ein offener Mechanismus

HISTORISCH · EXPLORATIV · LOKALE VORARBEIT

Lift: ein Ausgangspunkt, noch kein Nachweis

Nominal · 10.000 Updates je Modell · Lift PH / Low-Dimensional · 20 Rollouts je Trainingsseed



Gepoolt: BC 44/60 (73,3 %) · frühere Erweiterung 56/60 (93,3 %)
Drei Trainingsseeds sind die unabhängigen Trainingswiederholungen; 60 Rollouts sind keine 60 Seeds.

Keine Signifikanzbehauptung und kein Stabilitätsnachweis. Die vorgeschlagene neue Methode ist damit nicht validiert.
Quelle: praxis/reports/lift_ph_full_100ep_summary.json · Darstellung: nominal, alle drei vorhandenen Trainingsseeds

Was diese Messung trägt

Die frühere lokale Erweiterung erreicht nominal 56/60 statt 44/60 Erfolge. Es sind **drei Trainingsseeds mit je 20 Rollouts**. Das motiviert die Frage; die Grafik bestätigt weder die neue Methode noch deren Mechanismus [L2].

Was die späteren Prüfungen ändern

Die aus Expertendaten geschätzte Aktionsantwort war unter kontrollierten Eingriffen unzuverlässig. Der neue lokale Lossentwurf ist numerisch geprüft, aber untrainiert; eine vorgeschlagene Fehlerhülle bestand ihren unabhängigen Entwicklungstest nicht [L3].

Nächster kleiner Test: lokales A gegen festes A bei identischem lokalem B. Keine erneute große Trainingsserie, bevor Modellgüte, Abdeckung und Kosten plausibel sind.

Fünf Arme, eine Hauptfrage

Arm	Methode	Zweck
C0	Unverändertes BC	Referenzleistung
C1	BC + konsistente Sensoraugmentation	Einfachere Alternative
C2	BC + lokaler kalibrierter Loss; gleiches Gewicht	Ungewichtete Kontrolle
C3	C2 + Gewichte nach Modellgültigkeit	Vorgeschlagene Änderung
C4	C3 mit zufällig permutierten Gewichten	Gezielte Auswahl gegen Zufall

Was gleich bleibt

Architektur, Demosplit, Updatebudget, Optimizer, Batchreihenfolge und Evaluator. C2-C4 nutzen dieselben A/B-Modelle, Perturbationen und harten Domainmasken. C4 erhält dieselbe Gewichtsverteilung. Gradientennormen und effektive Abdeckung werden protokolliert.

Was gemessen wird

Fünf Bedingungen: nominal, Sensorbias +5/-5 mm sowie echter Aktionsimpuls in +x/-x. Der Hauptimpuls erfolgt zu einem gleichen festen frühen Zeitpunkt. Erfolg wird erst im gemeinsamen Bewertungsfenster danach gezählt. Dosis und Zeitpunkt werden im Entwicklungspilot festgelegt.

Hauptvergleich: C3 minus C2 bei gestörtem Taskerfolg.

Praktisches Ziel: +10 Prozentpunkte; nominal höchstens 5 Prozentpunkte schlechter. Schwellen vor Haupttest vereinbaren.

Umfang und Interpretation

5 neue Trainingsseeds × 5 Arme = **25 finale Läufe**. Je 50 gemeinsame neue Starts in 5 Bedingungen = **6.250 Episoden**. Bis zu 15 Entwicklungsläufe kommen hinzu. C3 gegen C4 prüft, ob die Zuordnung nach Modellgüte hilft; C3 gegen C1 den Nutzen über Augmentation hinaus.

Je Seed gepaarte Effekte und näherungsweise Unsicherheitsintervalle zeigen. Fünf Seeds bleiben wenig. Ein unklarer Effekt ist kein Gleichwertigkeitsnachweis.

Zwölf Wochen, ohne Cluster-Abhängigkeit

Zeitraum	Arbeit	Vorzeigbares Ergebnis
Woche 1-2 zuhause	Literatur, Baseline, feste Daten-/Versionsstände, Störungs- und Laufzeitpilot	Reproduzierbares Protokoll
Woche 3 zuhause	A/B-Gegenprüfung, Modellgüte, Abdeckung und Kosten	Entscheidung: A oder B
Woche 4-5 zuhause	Integration, Parität/Gradienten/Geometrie, kleiner Methodenpilot	Technisch geprüfte Methode
Woche 6 zuhause	Hyperparameter, Präzision und Testplan sperren; Text beginnen	Eingefrorenes Experimentpaket
Woche 7-8	Finale Lift-Läufe, seriell lokal oder identisch parallel im Cluster	Rohdaten und Unsicherheit
Woche 9	Eine Erweiterung bei abgeschlossenem Kern; sonst Fehleranalyse	Zweite Aufgabe oder vertiefte Diagnose
Woche 10-11	Auswertung, Diskussion, Schreiben, Medien	Vollständige Rohfassung
Woche 12	Reproduzierbarkeit, Korrektur, Vortrag, Puffer	Abgabefertige Arbeit

Rechenbudget transparent planen

Lokal vorhanden: RTX 5070 mit etwa 12 GB VRAM und Lift-Umgebung. Kleine State-BC-Läufe sind eine plausible Basis. Tatsächliche Zeiten zuerst messen; die Kalibrierung kann teurer sein als das Training.

Kosten: 25 × Trainingszeit + 6.250 × Episodenzeit + Kalibrierung + Entwicklung. Reines Planungsbeispiel: 4 s/Episode ergeben 6,9 h Evaluation; 10 s ergeben 17,4 h. Das sind keine neuen Messwerte.

Ohne Cluster: abgeschlossene Lift-Studie. **Mit Cluster:** zusätzliche Replikation oder eine zweite Aufgabe. Keine breite Suche über Aufgaben, Netzwerke und Störungsraster gleichzeitig.

Zwei Alternativen und ein klarer Einstieg

Alternative B: Zeitlich strukturierte Sensoraugmentation

Hypothese: Ein über ein Zeitfenster konstanter Trainingsbias verbessert Robustheit gegen anhaltenden Sensorbias stärker als unabhängiges Frame-Rauschen bei gleicher Randverteilung. Kein entsprechender Recoverygewinn durch echte Impulse erwartet.

Drei identische BC-RNN-Arme: ohne Rauschen, unabhängiges Rauschen, konstanter Fensterbias. Ein Gedächtnismodell ist hier wesentlich: Beim zustandslosen MLP kann dieselbe Randverteilung denselben erwarteten Loss erzeugen. Geringeres Modellrisiko, klarer Trainingsbeitrag.

Alternative C: Feedback oder Mittelung?

Hypothese: Häufigeres Replanning hilft nach Störungen stärker als bloßes temporales Ensembling. Dieselben vorhandenen Direct-Checkpoints mit zwei Aktionen, einer Aktion und einer gemittelten Aktion ausführen. Gripper gesondert behandeln. Wenig Training nötig; Schwerpunkt ist die Ausführung [S7-S8,S13].

So kannst du beginnen

> „Ich möchte nicht nur ein Modell trainieren, sondern eine konkrete Annahme prüfen: Hilft ein dynamikbasierter Zusatzloss dann mehr, wenn ich ihn nur dort stark gewichte, wo das lokale Modell zuverlässig ist? Ich starte mit Lift, trenne Messfehler von echten Störungen und vergleiche mit einfachen Kontrollen.“

Im Gespräch entscheiden

1. Genügt Adaption plus saubere Ablation als Methodenbeitrag?
2. Ist zusätzlicher Simulatorzugang im Training erlaubt?
3. Reicht eine gründliche Aufgabe als Mindestumfang?
4. Sind negative Ergebnisse und Alternative B akzeptabel?
5. Welche Clusterressourcen sind ab etwa Woche 7 realistisch?

15-Minuten-Ablauf: 2 min Frage · 3 min Literatur/Vorarbeiten · 4 min Experiment · 2 min Plan · 4 min Entscheidungen. Der ausführliche Leitfaden enthält einen 90-Sekunden-Sprechtext.

Vor dem Haupttest diese Punkte festlegen

1 / Datenzugang und Trennung

Offizielles Lift-PH mit vorhandenem 180/20-Demosplit. Innerhalb der Trainingsdemos Modellfit, Kalibrierung und Gegenprüfung demoweise trennen. Bereits genutzte Demos als Entwicklung markieren. Neue finale Startzustände sperren; sie dürfen weder Gewichte noch Checkpointwahl beeinflussen.

2 / Modellprüfung vor Training

A/B durch getrennte physisch konsistente Eingriffe identifizieren und auf anderen Eingriffen prüfen. Orientierung, Geschwindigkeit, Gripper, Controllerzustände und Kontakte kontrollieren. Vektorfehler, falsche Kontraktionsfreigaben, Abdeckung und Simulatorabfragen ausweisen. Die gescheiterte Fehlermarge nicht aus Prüfdaten nachjustieren.

Diskussionsvorschlag fürs Entwicklungsgate: mindestens 30% Abdeckung im beanspruchten Arbeitsbereich, höchstens 10% falsche Freigaben unter akzeptierten Prüffällen. Schwellen und Nenner vor Prüfung sperren. Dies sind praktische Vorschläge, keine bewiesenen Sicherheitsgrenzen.

3 / Aktive Abdeckung während des Lernens

Eingefrorene Gewichte bedeuten nicht konstante effektive Auswahl: Policyaktionen können den kalibrierten Bereich verlassen. Gleiche Maskierungsregel in C2-C4, Abdeckung je Phase und über die Zeit berichten. Kontaktfreie Aktivität allein belegt keinen Mechanismus in Kontaktphasen.

4 / Erfolg, Unsicherheit und Zusatzkosten

Hauptmetrik: voller Taskerfolg nach festem Impuls, beide Richtungen gleich gewichtet. Native Erfolgsbedingung im gemeinsamen Zeitfenster nach Eingriff auswerten; ein früherer Erfolg allein genügt nicht. Abbrüche nicht still aus dem Nenner entfernen.

95%-Intervalle näherungsweise über gekreuztes Resampling von Trainingsseed und gemeinsamem Start; Paarungen erhalten. Positiver Befund: praktisches Ziel erreicht, Gewinnintervall über null und untere nominale Differenzgrenze über -5 Punkten. Präzision in Woche 6 anhand des Piloten planen. Sonst explizit explorativ/unklar.

5 / Was ein negatives Ergebnis bedeutet

Augmentation gleich gut und billiger: Zusatzmodell nicht gerechtfertigt. Zufallsgewichte gleich gut: Gültigkeitsauswahl als Erklärung nicht gestützt. Besserer Modellfehler ohne Taskgewinn: Diagnose und Aufgabenerfolg auseinanderhalten. Alle Kalibrier-, Trainings- und Evaluationskosten bilanzieren.

Nachlesen und zeigen

[S1] Mandlekar et al. What Matters in Learning from Offline Human Demonstrations. CoRL 2021, PMLR 2022.
Originalquelle öffnen

[S2] robomimic: offizielle Algorithmen-Dokumentation; Datensatzlinks im ausführlichen Leitfaden.
Originalquelle öffnen

[S3] Mehta et al. Stable-BC. IEEE RA-L 2025. Autorenprojekt mit Demo-Video.
Originalquelle öffnen

[S4] Ke et al. CCIL: Continuity-based Data Augmentation for Corrective Imitation Learning. ICLR 2024.
Originalquelle öffnen

[S5] Deshpande et al. Data Efficient Behavior Cloning for Fine Manipulation via Continuity-based Corrective Labels. IROS 2024 laut Autoren.
Originalquelle öffnen

[S6] Chi et al. Diffusion Policy. RSS 2023. Autorenprojekt und Videos.
Originalquelle öffnen

[S7] Lazzati et al. Why Does Action Chunking Improve Behavioral Cloning Performance in Robotic Control? Preprint, 03.08.2026.
Originalquelle öffnen

[S8] Goyal. Measuring the Stability Assumption Behind Action Chunking. Preprint, 01.10.2026.
Originalquelle öffnen

[S9] Abyaneh et al. Contractive Dynamical Imitation Policies for Efficient Out-of-Sample Recovery. ICLR 2025.
Originalquelle öffnen

[S10] Abyaneh et al. Contractive Diffusion Policies. ICLR 2026.
Originalquelle öffnen

[S11-S13] DAgger (AISTATS 2011); DART (CoRL 2017); ACT (RSS 2023). Einzelne Original-Links im Leitfaden.
Originalquelle öffnen

Lokale Quellen und Medien

[L1] FORSCHUNGSPLAN.md (04.10.2026).
[L2] praxis/reports/lift_ph_full_100ep_summary.json.
[L3] SESSION_RESEARCH_REPORT.md der Lift-Session vom 04.10.2026.
[L4] Stack-Replikation und Replaymanifest vom 01.10.2026.

Im Begleitordner: ausführlicher Gesprächsleitfaden, Quellen-/Medienregie, zwei Grafiken, 10-Sekunden-Schemaanimation und ausgewählte historische Stack-Replays. Die Replays illustrieren eine andere Aufgabe, keine neue Evidenz für die Hypothese.